

Klasyfikacja wieloetykietowa sygnałów EKG z wykorzystaniem głębokich sieci neuronowych

Analiza patologii serca przy użyciu 1D CNN

Anna Gruca

Maj 2026

Projekt z zakresu uczenia maszynowego / analizy sygnałów biomedycznych

Streszczenie

Celem projektu było opracowanie systemu automatycznej klasyfikacji sygnałów EKG w podejściu wieloetykietowym (multi-label classification) z wykorzystaniem głębokich sieci neuronowych.

W projekcie wykorzystano zbiór danych PTB-XL, obejmujący rzeczywiste zapisy elektrokardiograficzne wraz z adnotacjami diagnostycznymi. Zaimplementowano pełny pipeline obejmujący preprocessing sygnału, segmentację, kodowanie etykiet, augmentację danych, balansowanie klas oraz trenowanie modelu 1D CNN.

Dodatkowo przeprowadzono analizę interpretowalności modelu z wykorzystaniem map istotności (saliency maps), umożliwiającą wizualizację fragmentów sygnału najbardziej wpływających na decyzję sieci.

Spis treści

1	Wstęp	4
1.1	Wprowadzenie do analizy sygnałów EKG	4
1.2	Zastosowanie uczenia maszynowego w medycynie	4
1.3	Cel projektu	4
2	Zbiór danych PTB-XL	5
2.1	Opis zbioru danych	5
2.2	Kodowanie diagnostyczne SCP	5
2.3	Rozkład klas	6
2.4	Charakter multi-label	7
2.5	Przykładowe sygnały EKG	8
3	Przetwarzanie wstępne sygnału EKG	9
3.1	Filtracja Butterwortha	9
3.2	Normalizacja sygnału	10
3.3	Segmentacja sygnału	10
3.4	Pipeline przetwarzania	11
3.5	Augmentacja danych	11
3.5.1	Dodawanie szumu gaussowskiego	11
3.5.2	Skalowanie amplitudy	11
3.5.3	Przesunięcia czasowe	12
3.6	Wpływ augmentacji na proces uczenia	12
4	Architektura modelu	13
4.1	Wybór architektury CNN 1D	13
4.2	Warstwy konwolucyjne	13
4.3	Batch Normalization oraz Dropout	14
4.3.1	Batch Normalization	14
4.3.2	Dropout	14
4.4	Funkcja straty BCEWithLogitsLoss	14
4.5	Problem niezbalansowanych klas	15
5	Proces treningu modelu	16
5.1	Podział danych	16
5.2	Optymalizator Adam	16
5.3	Funkcja kosztu BCEWithLogitsLoss	17
5.4	Balansowanie klas	17
5.5	Early Stopping	18
5.6	Threshold Tuning	19
5.7	Wpływ liczby rekordów na jakość modelu	20
6	Ewaluacja modelu	21
6.1	Metryki ewaluacyjne	21
6.2	Accuracy	21
6.3	Precision i Recall	22
6.4	F1-score	22
6.5	Wyniki klasyfikacji	22

6.6	ROC Curve oraz ROC-AUC	23
6.7	Macierze pomyłek	24
6.8	Średnie prawdopodobieństwa predykcji	27
7	Interpretowalność modelu (Explainable AI)	28
7.1	Motywacja medyczna	28
7.2	Saliency Maps	28
7.3	Przykład interpretacji predykcji	29
7.4	Interpretacja medyczna wyniku	29
7.5	Wizualizacja Saliency Map	29
7.6	Interpretacja wizualna	30
7.7	Znaczenie kliniczne interpretowalności	30
7.8	Podsumowanie	30
8	Podsumowanie i wnioski końcowe	31
8.1	Problem niezbalansowanych klas	31
8.2	Ograniczenia modelu	31
8.3	Możliwe usprawnienia modelu	32
8.4	Wnioski końcowe	32
9	Bibliografia	33

1 Wstęp

1.1 Wprowadzenie do analizy sygnałów EKG

Elektrokardiografia (EKG) jest jedną z podstawowych metod diagnostycznych stosowanych w kardiologii. Sygnał EKG odzwierciedla aktywność elektryczną serca i pozwala na wykrywanie wielu patologii, takich jak zawał mięśnia sercowego, zaburzenia przewodzenia czy przerost mięśnia sercowego.

Interpretacja sygnałów EKG wymaga wiedzy specjalistycznej i jest czasochłonna, szczególnie w przypadku dużych zbiorów danych.

1.2 Zastosowanie uczenia maszynowego w medycynie

W ostatnich latach dynamicznie rozwijają się metody oparte na uczeniu głębokim, które pozwalają na automatyczną analizę sygnałów biomedycznych.

Sieci neuronowe, w szczególności konwolucyjne (CNN), są skuteczne w wykrywaniu lokalnych wzorców czasowych występujących w sygnałach EKG.

Systemy oparte na AI mogą wspierać lekarzy poprzez:

- przyspieszenie analizy EKG,
- automatyczne wykrywanie anomalii,
- zmniejszenie obciążenia diagnostycznego,
- identyfikację subtelnych wzorców patologicznych.

1.3 Cel projektu

Celem projektu było stworzenie systemu klasyfikacji wieloetykietowej sygnałów EKG, który umożliwi jednocześnie wykrywanie wielu patologii serca.

Zrealizowany pipeline obejmuje:

- przetwarzanie wstępne sygnału EKG,
- filtrację i normalizację,
- segmentację sygnału,
- kodowanie wieloetykietowe,
- budowę modelu CNN 1D,
- balansowanie klas,
- optymalizację progów decyzyjnych,
- analizę interpretowalności modelu.

2 Zbiór danych PTB-XL

2.1 Opis zbioru danych

W projekcie wykorzystano zbiór danych PTB-XL, który jest jednym z największych publicznych zbiorów sygnałów EKG.

Zbiór zawiera:

- ponad 21 000 zapisów EKG,
- dane od wielu pacjentów,
- adnotacje diagnostyczne,
- wieloetykietowe klasy patologii.

Źródło danych: <https://physionet.org/content/ptb-xl/1.0.3/>

2.2 Kodowanie diagnostyczne SCP


Każdy zapis EKG posiada przypisane kody SCP (Standard Communication Protocol), które opisują rozpoznane patologie.

W projekcie zostały one zmapowane na pięć głównych superklas:

- **NORM** — zapis prawidłowy,
- **MI** — zawał mięśnia sercowego,
- **STTC** — zmiany ST/T,
- **CD** — zaburzenia przewodzenia,
- **HYP** — przerost mięśnia sercowego.

2.3 Rozkład klas


Na rysunku przedstawiono rozkład częstości występowania poszczególnych klas w zbiorze danych.



Rysunek 1: Rozkład klas diagnostycznych w zbiorze PTB-XL.

2.4 Charakter multi-label


Zbiór danych ma charakter multi-label, co oznacza, że pojedynczy zapis EKG może być przypisany do więcej niż jednej klasy diagnostycznej.



Rysunek 2: Liczba etykiet przypisanych do pojedynczego zapisu EKG.

2.5 Przykładowe sygnały EKG

Na rysunkach przedstawiono przykładowe przebiegi sygnału dla różnych patologii.



Rysunek 3: Przykładowy zapis EKG (różne klasy diagnostyczne).

3 Przetwarzanie wstępne sygnału EKG

Sygnał elektrokardiograficzny (ECG) charakteryzuje się dużą wrażliwością na zakłócenia, takie jak szum sieciowy, dryft linii izoelektrycznej oraz artefakty ruchowe pacjenta. Z tego powodu kluczowym etapem w pipeline uczenia maszynowego jest odpowiednie przetwarzanie wstępne sygnału.

W niniejszym projekcie zastosowano trzy główne etapy preprocessingu:

- filtrację pasmowo-przepustową Butterwortha,
- normalizację sygnału,
- segmentację sygnału na okna czasowe.

3.1 Filtracja Butterwortha

W pierwszym kroku zastosowano filtr pasmowo-przepustowy Butterwortha rzędu 4, którego zadaniem jest usunięcie szumu o bardzo niskiej oraz bardzo wysokiej częstotliwości.

Zakres częstotliwości został dobrany zgodnie z charakterystyką sygnału EKG:

- dolna granica: 0.5 Hz (usunięcie dryftu linii bazowej),
- górna granica: 40 Hz (redukcja szumu wysokoczęstotliwościowego).


Filtr Butterwortha charakteryzuje się maksymalnie płaską charakterystyką w paśmie przepustowym, co pozwala na zachowanie kształtu istotnych komponentów sygnału (złamki P, QRS, T).

Matematycznie filtr definiowany jest poprzez transmitancję:

$$H(s) = \frac{1}{1 + \left(\frac{s}{\omega_c}\right)^{2n}} \quad (1)$$

gdzie n oznacza rząd filtra, a ω_c częstotliwość odcięcia.

W celu lepszego zrozumienia działania pipeline przetwarzania sygnału EKG przedstawiono wizualizację poszczególnych etapów.



Rysunek 4: Porównanie sygnału EKG przed i po filtracji Butterwortha.

3.2 Normalizacja sygnału

Po filtracji sygnał został poddany normalizacji typu z-score:

$$x' = \frac{x - \mu}{\sigma + \epsilon} \quad (2)$$

gdzie:

- μ — średnia sygnału,
- σ — odchylenie standardowe,
- ϵ — mała stała numeryczna stabilizująca obliczenia.

Normalizacja zapewnia stabilność uczenia sieci neuronowej oraz redukuje wpływ różnic amplitudy pomiędzy pacjentami.

3.3 Segmentacja sygnału

Sygnał EKG ma zmienną długość, dlatego został podzielony na stałe okna czasowe o długości odpowiadającej 2 sekundom sygnału (przy częstotliwości próbkowania 360 Hz daje to 720 próbek).


Segmentacja realizowana jest metodą okienkowania bez nakładania się:

$$x_i = x[t : t + L] \quad (3)$$

gdzie:

- $L = 720$ — długość okna,
- t — indeks startowy segmentu.

Każdy sygnał wejściowy jest następnie reprezentowany jako zbiór krótkich segmentów, co zwiększa liczbę próbek uczących oraz umożliwia modelowi naukę lokalnych wzorców patologii.



Rysunek 5: Przykład segmentacji sygnału EKG na okna 2-sekundowe.

3.4 Pipeline przetwarzania

Cały pipeline można zapisać jako sekwencję operacji:

$$x \rightarrow \text{Butterworth Filter} \rightarrow \text{Normalization} \rightarrow \text{Segmentation} \quad (4)$$

Ostatecznie model otrzymuje dane w postaci tensorów o wymiarze:

$$(N, 1, 720) \quad (5)$$

gdzie N oznacza liczbę segmentów.

3.5 Augmentacja danych

W celu zwiększenia zdolności generalizacji modelu oraz ograniczenia zjawiska przeuczenia (overfittingu) zastosowano augmentację sygnałów EKG.

Augmentacja polega na generowaniu nowych wariantów sygnałów treningowych poprzez wprowadzanie kontrolowanych modyfikacji zachowujących istotne cechy diagnostyczne sygnału.

W przeciwieństwie do klasycznych problemów przetwarzania obrazów, augmentacja sygnałów biomedycznych musi zachowywać charakterystyczną morfologię przebiegu EKG, aby nie zaburzyć informacji klinicznej.

W projekcie zastosowano następujące techniki augmentacji:

- dodawanie szumu gaussowskiego,
- losowe skalowanie amplitudy sygnału,
- niewielkie przesunięcia czasowe sygnału,
- jittering.

3.5.1 Dodawanie szumu gaussowskiego

Dodawanie niewielkiego szumu gaussowskiego pozwala zwiększyć odporność modelu na zakłócenia pomiarowe występujące w rzeczywistych zapisach EKG.

Augmentowany sygnał można opisać równaniem:

$$x' = x + \mathcal{N}(0, \sigma^2) \quad (6)$$

gdzie:

- x — oryginalny sygnał,
- $\mathcal{N}(0, \sigma^2)$ — szum gaussowski o średniej 0.

3.5.2 Skalowanie amplitudy

Skalowanie amplitudy pozwala symulować różnice pomiędzy pacjentami oraz zmiany wynikające z jakości pomiaru.

$$x' = \alpha x \quad (7)$$

gdzie α jest losowym współczynnikiem skalowania.

3.5.3 Przesunięcia czasowe

Niewielkie przesunięcia sygnału w osi czasu umożliwiają zwiększenie odporności modelu na lokalne zmiany położenia załamków.


$$x'(t) = x(t + \Delta t) \quad (8)$$

gdzie Δt oznacza niewielkie przesunięcie czasowe.

3.6 Wpływ augmentacji na proces uczenia

Augmentacja danych zwiększyła różnorodność próbek treningowych oraz poprawiła zdolność modelu do generalizacji na nieznanymi danych testowych.

Dzięki augmentacji model nauczył się identyfikować istotne wzorce patologiczne niezależnie od niewielkich zakłóceń sygnału.



Rysunek 6: Przykłady augmentacji sygnału EKG.

4 Architektura modelu

4.1 Wybór architektury CNN 1D

Do klasyfikacji sygnałów EKG zastosowano jednowymiarową konwolucyjną sieć neuronową (1D CNN).

Architektury CNN są szczególnie skuteczne w analizie danych sekwencyjnych i sygnałowych, ponieważ umożliwiają automatyczne wykrywanie lokalnych wzorców w sygnale.

W przypadku sygnałów EKG model może nauczyć się rozpoznawania:

- zespołów QRS,
- załamków P i T,
- zmian odcinka ST,
- zaburzeń rytmu,
- lokalnych anomalii morfologicznych.

W przeciwieństwie do klasycznych metod opartych na ręcznej ekstrakcji cech, sieć CNN uczy się reprezentacji cech bezpośrednio z danych wejściowych.

Zastosowanie architektury 1D CNN zamiast 2D CNN wynika z faktu, że sygnał EKG jest sygnałem czasowym jednowymiarowym.

Operacja konwolucji jednowymiarowej może zostać zapisana jako:

$$y(t) = \sum_{k=0}^{K-1} x(t-k)w(k) \quad (9)$$

gdzie:

- x — sygnał wejściowy,
- w — filtr konwolucyjny,
- K — rozmiar jądra konwolucji.

Konwolucja umożliwia modelowi wykrywanie lokalnych zależności czasowych w sygnale EKG.

4.2 Warstwy konwolucyjne

Model składa się z trzech bloków konwolucyjnych.

Każdy blok zawiera:

- warstwę Conv1D,
- normalizację BatchNorm,
- funkcję aktywacji ReLU,
- warstwę MaxPooling.

Pierwsze warstwy sieci uczą się prostych lokalnych wzorców sygnału, natomiast głębsze warstwy wykrywają bardziej złożone cechy diagnostyczne.

Zastosowanie MaxPooling pozwala zmniejszyć wymiar reprezentacji cech oraz ograniczyć liczbę parametrów modelu.

4.3 Batch Normalization oraz Dropout

W modelu zastosowano mechanizmy regularizacji mające na celu poprawę stabilności uczenia oraz ograniczenie przeuczenia.

4.3.1 Batch Normalization

Warstwa Batch Normalization normalizuje aktywacje pomiędzy kolejnymi warstwami sieci. Dzięki temu:

- proces uczenia jest bardziej stabilny,
- możliwe jest stosowanie większych współczynników uczenia,
- zredukowany jest problem zanikającego gradientu.

4.3.2 Dropout

Dropout polega na losowym wyłączaniu części neuronów podczas treningu.

W projekcie zastosowano:

- dropout 0.3 w części konwolucyjnej,
- dropout 0.5 w klasyfikatorze.

Mechanizm ten zmniejsza ryzyko nadmiernego dopasowania modelu do danych treningowych.

4.4 Funkcja straty BCEWithLogitsLoss

Problem klasyfikacji został sformułowany jako zadanie multi-label classification.

Pojedynczy zapis EKG może zawierać więcej niż jedną patologię jednocześnie, dlatego zastosowano funkcję aktywacji sigmoid zamiast softmax.

Dla każdej klasy model przewiduje niezależne prawdopodobieństwo wystąpienia danej patologii.

Zastosowana funkcja straty BCEWithLogitsLoss łączy:

- funkcję sigmoid,
- Binary Cross Entropy.

Funkcja straty może zostać zapisana jako:

$$L = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(x_i)) + (1 - y_i) \log(1 - \sigma(x_i))] \quad (10)$$

gdzie:

- y_i — rzeczywista etykieta,
- $\sigma(x_i)$ — predykcja modelu po sigmoid.

4.5 Problem niezbalansowanych klas

Zbiór PTB-XL charakteryzuje się nierównym rozkładem klas.

Klasy takie jak NORM występują znacznie częściej niż klasy HYP lub MI.

Taka nierównowaga może prowadzić do sytuacji, w której model preferuje przewidywanie klas dominujących.

W celu ograniczenia tego problemu zastosowano mechanizm `pos_weight` w funkcji `BCEWithLogitsLoss`.

Wagi klas zostały wyznaczone na podstawie liczby wystąpień poszczególnych klas:

$$w_c = \frac{N}{2n_c} \tag{11}$$

gdzie:

- N — liczba wszystkich próbek,
- n_c — liczba próbek klasy c .

Dzięki temu model silniej penalizuje błędy dla klas rzadkich.

5 Proces treningu modelu

Po przygotowaniu danych oraz zaprojektowaniu architektury sieci neuronowej przeprowadzono proces uczenia modelu klasyfikującego wieloetykietowe sygnały EKG. Celem treningu było nauczenie modelu rozpoznawania współwystępujących patologii kardiologicznych na podstawie fragmentów sygnału elektrokardiograficznego.

5.1 Podział danych

Dane zostały podzielone na trzy niezależne zbiory:

- **zbiór treningowy (train)** – używany do aktualizacji wag modelu,
- **zbiór walidacyjny (validation)** – używany do monitorowania procesu uczenia,
- **zbiór testowy (test)** – wykorzystywany wyłącznie do końcowej oceny modelu.

W projekcie zastosowano następujący schemat podziału danych:

$$80\% \text{ train} \quad 20\% \text{ test} \quad (12)$$

Następnie zbiór treningowy został dodatkowo podzielony:

$$80\% \text{ train} \quad 20\% \text{ validation} \quad (13)$$

Takie podejście umożliwia:

- monitorowanie overfittingu,
- kontrolowanie procesu uczenia,
- zastosowanie mechanizmu Early Stopping.

5.2 Optymalizator Adam

Do optymalizacji wag modelu wykorzystano algorytm **Adam (Adaptive Moment Estimation)**.

Adam jest jedną z najczęściej stosowanych metod optymalizacji w głębokim uczeniu ze względu na:

- szybkie tempo zbieżności,
- adaptacyjny dobór współczynnika uczenia,
- stabilność treningu,
- skuteczność przy dużych modelach neuronowych.

W projekcie wykorzystano następujące parametry:

```
optimizer = torch.optim.Adam(  
    model.parameters(),  
    lr=0.001  
)
```


Współczynnik uczenia:

$$lr = 0.001 \quad (14)$$

zapewniał stabilne uczenie modelu bez gwałtownych skoków funkcji kosztu.

5.3 Funkcja kosztu BCEWithLogitsLoss

Ze względu na wieloetykietowy charakter problemu zastosowano funkcję kosztu:

$$\text{BCEWithLogitsLoss} \quad (15)$$

która łączy:

- funkcję sigmoidalną,
- binarną entropię krzyżową.

Dla pojedynczej klasy funkcja kosztu ma postać:

$$L = -[y \log(\sigma(x)) + (1 - y) \log(1 - \sigma(x))] \quad (16)$$

gdzie:

- y – etykieta rzeczywista,
- x – logit modelu,
- $\sigma(x)$ – funkcja sigmoidalna.

Zastosowanie funkcji BCEWithLogitsLoss było szczególnie istotne, ponieważ:

- jedna próbka może należeć do wielu klas jednocześnie,
- klasy są niezależne od siebie,
- model zwraca prawdopodobieństwo dla każdej patologii oddzielnie.

5.4 Balansowanie klas

Zbiór PTB-XL charakteryzuje się znaczną nierównowagą klas. Niektóre patologie występują znacznie częściej niż inne.

Bez zastosowania odpowiednich mechanizmów model miał tendencję do:

- ignorowania rzadkich klas,
- przewidywania głównie klasy dominującej,
- osiągnięcia wysokiej accuracy przy niskiej wartości recall dla klas mniejszościowych.

W celu przeciwdziałania temu problemowi wykorzystano parametr:

$$\text{pos_weight} \tag{17}$$

w funkcji BCEWithLogitsLoss.

Wagi klas wyznaczono zgodnie z zależnością:

$$w_i = \frac{N}{2 \cdot n_i} \tag{18}$$

gdzie:

- N – liczba wszystkich próbek,
- n_i – liczba wystąpień klasy i .

Dzięki temu model silniej karał błędną klasyfikację klas rzadkich.

Po zastosowaniu balansowania zaobserwowano:

- wzrost recall dla klas MI, CD oraz HYP,
- poprawę macro F1-score,
- bardziej stabilne predykcje modelu.

5.5 Early Stopping

W celu ograniczenia zjawiska przeuczenia zastosowano mechanizm:

$$\text{Early Stopping} \tag{19}$$

Polega on na monitorowaniu błędu walidacyjnego podczas treningu.


Jeżeli przez określoną liczbę epok model nie poprawia wyniku walidacyjnego, trening zostaje zatrzymany.

W projekcie wykorzystano:

- $\text{patience} = 5$,
- monitorowanie validation loss.

Mechanizm ten:

- zmniejsza ryzyko overfittingu,
- skraca czas treningu,
- pozwala zachować najlepszy model.



Rysunek 7: Krzywa funkcji kosztu podczas treningu

Na wykresie można zaobserwować:

- stabilny spadek funkcji kosztu,
- brak gwałtownego wzrostu validation loss,
- poprawną zbieżność procesu uczenia.

5.6 Threshold Tuning

Model zwraca prawdopodobieństwa przynależności do poszczególnych klas.

Standardowo przyjmuje się próg decyzyjny:

$$p > 0.5 \quad (20)$$

Jednak przy niezbalansowanych danych taki próg często nie jest optymalny.

W projekcie przeprowadzono strojenie progów decyzyjnych osobno dla każdej klasy.

Przeszukiwano zakres:

$$0.1 \leq threshold \leq 0.9 \quad (21)$$

w celu maksymalizacji metryki F1-score.

Dzięki temu:

- zwiększono recall dla klas rzadkich,
- poprawiono macro F1-score,
- uzyskano bardziej zbalansowane predykcje.

Przykładowe zoptymalizowane progi:

Klasa	Optymalny próg
NORM	0.35
MI	0.45
STTC	0.55
CD	0.35
HYP	0.45

Tabela 1: Przykładowe progi decyzyjne po threshold tuning


5.7 Wpływ liczby rekordów na jakość modelu

Model był trenowany na różnych wielkościach zbioru danych:

- 500 rekordów,
- 1000 rekordów,
- 5000 rekordów,
- 10000 rekordów,
- 20000 rekordów.

Zaobserwowano, że:

- większa liczba rekordów poprawia stabilność modelu,
- zwiększa się wartość ROC-AUC,
- poprawia się macro F1-score,
- model lepiej generalizuje na dane testowe.



Rysunek 8: Wpływ liczby rekordów na wartość F1-score

6 Ewaluacja modelu

Po zakończeniu procesu treningu przeprowadzono szczegółową ocenę jakości działania modelu. Analiza obejmowała zarówno klasyczne metryki uczenia maszynowego, jak i metody interpretacji jakości klasyfikacji wieloetykietowej.

6.1 Metryki ewaluacyjne

Ze względu na charakter problemu multi-label classification sama accuracy nie jest wystarczającą metryką oceny modelu. W projekcie wykorzystano następujące miary jakości:

- Accuracy,
- Precision,
- Recall,
- F1-score,
- ROC Curve,
- ROC-AUC,
- Confusion Matrix.

6.2 Accuracy

Accuracy określa procent poprawnie sklasyfikowanych próbek.

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \quad (22)$$

gdzie:

- TP – True Positive,
- TN – True Negative,
- FP – False Positive,
- FN – False Negative.

W problemach medycznych accuracy może być jednak mylące, szczególnie przy niezbalansowanych klasach. Model może osiągać wysoką accuracy poprzez przewidywanie głównie klas dominujących.

Z tego powodu większy nacisk położono na metrykę F1-score.

6.3 Precision i Recall

Precision określa, jaki procent wykrytych patologii był poprawny:

$$Precision = \frac{TP}{TP + FP} \quad (23)$$

Wysoka precision oznacza małą liczbę fałszywych alarmów.

Recall określa, jaki procent rzeczywistych patologii został wykryty przez model:

$$Recall = \frac{TP}{TP + FN} \quad (24)$$

W zastosowaniach medycznych recall jest szczególnie istotny, ponieważ pominięcie choroby może mieć poważne konsekwencje diagnostyczne.

6.4 F1-score

F1-score stanowi harmoniczną średnią precision oraz recall:

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall} \quad (25)$$

Metryka ta jest szczególnie użyteczna przy:

- niezbalansowanych klasach,
- problemach multi-label,
- danych medycznych.

W projekcie główną metryką jakości był:

$$Macro\ F1 = 0.526 \quad (26)$$

Wartość ta oznacza, że model osiąga umiarkowanie dobrą skuteczność jednocześnie dla wszystkich klas, również tych rzadszych.

6.5 Wyniki klasyfikacji

Tabela przedstawia końcowe wyniki modelu dla poszczególnych klas.

Klasa	Precision	Recall	F1-score	Support
NORM	0.76	0.82	0.79	1882
MI	0.42	0.58	0.49	889
STTC	0.53	0.75	0.62	944
CD	0.79	0.21	0.34	875
HYP	0.30	0.58	0.40	500

Tabela 2: Wyniki klasyfikacji dla poszczególnych klas

Można zauważyć, że:

- najwyższą skuteczność osiągnięto dla klasy NORM,
- model dobrze wykrywa STTC,
- klasy HYP oraz MI pozostają trudniejsze do klasyfikacji,
- klasa CD charakteryzuje się wysoką precision, lecz niższym recall.

6.6 ROC Curve oraz ROC-AUC

Krzywa ROC (Receiver Operating Characteristic) przedstawia zależność pomiędzy:

- True Positive Rate,
- False Positive Rate.


Pole pod krzywą ROC określane jest jako:

$$AUC = \text{Area Under Curve} \quad (27)$$

Wartość:

- $AUC = 1$ oznacza klasyfikator idealny,
- $AUC = 0.5$ odpowiada losowemu zgadywaniu.

W projekcie dla większości klas uzyskano wyraźnie lepsze wyniki od klasyfikacji losowej, co potwierdza zdolność modelu do rozróżniania patologii.



Rysunek 9: Krzywe ROC dla poszczególnych klas

Na wykresie można zauważyć, że:


- klasy NORM oraz STTC osiągają najwyższe wartości AUC,
- model gorzej radzi sobie z klasą CD i MI,
- wszystkie krzywe znajdują się powyżej przekątnej klasyfikacji losowej.

6.7 Macierze pomyłek


Do analizy błędów modelu wykorzystano macierze pomyłek (Confusion Matrix).
Macierz pomyłek przedstawia:

- poprawne klasyfikacje,
- fałszywe alarmy,
- niewykryte przypadki chorób.


Dla problemu multi-label wygenerowano osobną macierz dla każdej klasy.




Rysunek 10: Macierz pomyłek dla klasy NORM




Rysunek 11: Macierz pomyłek dla klasy MI



Rysunek 12: Macierz pomyłek dla klasy STTC



Rysunek 13: Macierz pomyłek dla klasy CD



Rysunek 14: Macierz pomyłek dla klasy HYP

Analiza macierzy pomyłek pokazuje, że:

- model poprawnie rozpoznaje większość sygnałów normalnych,
- klasy rzadkie generują większą liczbę false negatives,
- threshold tuning poprawił wykrywalność patologii.

6.8 Średnie prawdopodobieństwa predykcji

Dodatkowo przeanalizowano średnie prawdopodobieństwa przypisywane przez model do poszczególnych klas.

Klasa	Średnie prawdopodobieństwo
NORM	0.538
MI	0.339
STTC	0.302
CD	0.356
HYP	0.272

Tabela 3: Średnie prawdopodobieństwa predykcji modelu

Najwyższe średnie prawdopodobieństwo uzyskała klasa NORM, co jest zgodne z dominacją tej klasy w zbiorze danych.

7 Interpretowalność modelu (Explainable AI)

W zastosowaniach medycznych sama predykcja modelu nie jest wystarczająca do praktycznego wykorzystania w diagnostyce. Kluczowe znaczenie ma możliwość wyjaśnienia, **na podstawie których fragmentów sygnału model podjął decyzję**.

W tym celu zastosowano metody Explainable AI (XAI), w szczególności **mapy wrażliwości (Saliency Maps)**.

7.1 Motywacja medyczna

W klasycznej diagnostyce kardiologicznej lekarz analizuje:

- załamki P, QRS, T,
- odstępy czasowe (PR, QT),
- zmiany amplitudy i morfologii sygnału,
- nieregularności rytmu serca.

Analogicznie, interpretowalność modelu pozwala odpowiedzieć na pytanie:

Czy model podejmuje decyzję na podstawie klinicznie istotnych fragmentów sygnału EKG?

7.2 Saliency Maps

Mapa wrażliwości (Saliency Map) określa, które fragmenty wejściowego sygnału miały największy wpływ na decyzję modelu.

Formalnie obliczana jest jako wartość gradientu:

$$S = \left| \frac{\partial y_c}{\partial x} \right| \quad (28)$$

gdzie:

- y_c – wynik modelu dla klasy c ,
- x – sygnał wejściowy,
- S – mapa istotności.

Duże wartości gradientu oznaczają, że niewielka zmiana sygnału w danym miejscu znacząco wpływa na decyzję modelu.

7.3 Przykład interpretacji predykcji

Dla losowej próbki sygnału EKG uzyskano następujące wyniki:

```
input shape: (4000, 1, 720)
```

```
True label:  
[1. 0. 0. 0. 0.]
```

Predicted probabilities:

NORM: 0.773

MI: 0.200

STTC: 0.052

CD: 0.268

HYP: 0.103

Predicted class: NORM

Model zaklasyfikował sygnał jako **NORM**, co oznacza brak wykrytych patologii.

7.4 Interpretacja medyczna wyniku


Wysokie prawdopodobieństwo klasy NORM sugeruje, że model:

- nie wykrył istotnych zaburzeń rytmu,
- uznał morfologię sygnału za fizjologiczną,
- nie zidentyfikował charakterystycznych cech patologii (np. zmian ST, zaburzeń QRS).

Jednocześnie niższe wartości dla klas patologicznych wskazują, że model nie znajduje silnych przesłanek klinicznych dla ich obecności.

7.5 Wizualizacja Saliency Map

Na podstawie gradientów wygenerowano mapę istotności, która pokazuje, które fragmenty sygnału EKG były kluczowe dla decyzji modelu.



Rysunek 15: Mapa wrażliwości (Saliency Map) dla sygnału EKG

7.6 Interpretacja wizualna

Analiza saliency map pozwala zauważyć, że model koncentruje się na:

- wybranych fragmentach zespołu QRS,
- zmianach amplitudy sygnału,
- lokalnych deformacjach przebiegu EKG.

W idealnym przypadku aktywacje modelu powinny pokrywać się z klinicznie istotnymi elementami sygnału, takimi jak:

- załamki QRS (depolaryzacja komór),
- załamki T (repolaryzacja),
- odstępy między cyklami serca.

7.7 Znaczenie kliniczne interpretowalności

Zastosowanie metod Explainable AI w analizie EKG ma kluczowe znaczenie, ponieważ:

- zwiększa zaufanie do modelu w zastosowaniach medycznych,
- umożliwia weryfikację poprawności decyzji przez specjalistów,
- pozwala wykrywać potencjalne błędy modelu,
- wspiera integrację systemów AI z praktyką kliniczną.

W szczególności w diagnostyce kardiologicznej interpretowalność jest niezbędna, ponieważ decyzje modelu mogą mieć bezpośredni wpływ na dalsze postępowanie medyczne pacjenta.

7.8 Podsumowanie

Metody interpretowalności zastosowane w projekcie pokazują, że model CNN nie działa wyłącznie jako „czarna skrzynka”, lecz może dostarczać informacji o tym, **które fragmenty sygnału EKG są istotne dla diagnozy**. Stanowi to istotny krok w kierunku zastosowań systemów AI w medycynie klinicznej.

8 Podsumowanie i wnioski końcowe

W ramach projektu zbudowano oraz przetestowano model głębokiego uczenia oparty o sieć konwolucyjną 1D (1D CNN) do klasyfikacji sygnałów EKG w problemie wieloetykiętowym.

Model został wytrenowany na zbiorze PTB-XL i osiągnął zdolność rozpoznawania pięciu głównych klas patologii kardiologicznych: NORM, MI, STTC, CD oraz HYP. Przeprowadzono eksperymenty dla różnych wielkości zbioru danych, analizę wpływu balansowania klas, tuning progów decyzyjnych oraz interpretację wyników z wykorzystaniem metryk klasyfikacyjnych i metod Explainable AI.

8.1 Problem niezbalansowanych klas

Jednym z głównych wyzwań w projekcie był silnie niezbalansowany rozkład klas w zbiorze PTB-XL.

Zaobserwowano, że:

- klasy dominujące (np. NORM) były znacznie lepiej klasyfikowane,
- klasy rzadkie (np. HYP) miały niższy recall i większą liczbę false negatives,
- model miał tendencję do preferowania klas częstych.

Problem ten częściowo rozwiązano poprzez zastosowanie:

- wag klas w funkcji straty (pos_weight),
- threshold tuning,
- analizę metryk macro F1 zamiast accuracy.

8.2 Ograniczenia modelu

Pomimo uzyskanych wyników model posiada kilka istotnych ograniczeń:

- ograniczona zdolność wykrywania rzadkich patologii,
- wrażliwość na jakość segmentacji sygnału,
- brak pełnego modelowania zależności czasowych długiego zasięgu,
- uproszczona reprezentacja sygnału (1 kanał, pojedyncze odprowadzenie),
- ograniczona interpretowalność w porównaniu do klasycznej diagnostyki klinicznej.

8.3 Możliwe usprawnienia modelu

W przyszłych pracach można rozważyć następujące ulepszenia:

- **Architektura modelu:**

- dodanie bloków rezydualnych (ResNet-like 1D CNN),
- zastosowanie sieci hybrydowych CNN + LSTM,
- wykorzystanie mechanizmu attention (self-attention / temporal attention).

- **Dane i preprocessing:**

- rozszerzenie augmentacji sygnałów EKG,
- wykorzystanie wszystkich odprowadzeń (multi-lead ECG),
- bardziej zaawansowana filtracja adaptacyjna.

- **Uczenie modelu:**

- focal loss zamiast BCE dla niebalansowanych klas,
- bardziej zaawansowane metody oversamplingu,
- tuning hiperparametrów (learning rate, batch size).

- **Interpretowalność:**

- Grad-CAM dla sygnałów 1D,
- SHAP dla modeli głębokich,
- porównanie aktywacji modelu z punktami klinicznymi EKG.

8.4 Wnioski końcowe

Zbudowany model CNN 1D wykazuje zdolność do wykrywania patologii serca na podstawie sygnału EKG oraz osiąga satysfakcjonujące wyniki w warunkach wieloetykietowej klasyfikacji.

Najważniejszymi obserwacjami są:

- znaczący wpływ wielkości zbioru danych na jakość modelu,
- kluczowa rola balansowania klas w problemach medycznych,
- istotna poprawa wyników dzięki threshold tuning,
- duże znaczenie interpretowalności w zastosowaniach klinicznych.

Model stanowi solidną bazę do dalszych prac nad systemami wspomagania diagnostyki kardiologicznej z wykorzystaniem sztucznej inteligencji.

9 Bibliografia

Literatura

- [1] Wagner, P. et al. *PTB-XL, a large publicly available electrocardiography dataset*. Scientific Data, 2020.
- [2] Kiranyaz, S. et al. *Real-time patient-specific ECG classification by 1-D convolutional neural networks*. IEEE Transactions on Biomedical Engineering.
- [3] Kingma, D. P., Ba, J. *Adam: A Method for Stochastic Optimization*. 2014.
- [4] Goodfellow, I., Bengio, Y., Courville, A. *Deep Learning*. MIT Press.
- [5] Samek, W., Wiegand, T., Müller, K.-R. *Explainable Artificial Intelligence: Understanding, Visualizing and Interpreting Deep Learning Models*.